



Trabalho 1 – Inteligência Artificial II 2026/02

Feito Por : Andrey Ricardo Lucca Peil e Arthur Santiago Pereira de Sena

Modelo de relatório (PDF)

Seção	O que apresentar
Dataset	“spotify_data_processed.csv” https://www.kaggle.com/datasets/yoges hm01/spotify-artist-streaming-analytics-20152025
Problema e objetivo	Problema: Um usuário quer descobrir músicas com um gênero similar a uma música escolhida que eles já ouvem, como um tipo de recomendação baseada no seu estilo musical Objetivo: dada uma música de entrada, identificar a qual cluster de estilo ela pertence, com base em seu gênero e em seus atributos de áudio (danceability, energy, duração, tempo, loudness, instrumentality), e recomendar as músicas mais similares dentro desse mesmo cluster, ordenadas por proximidade no espaço de atributos
Exploração e preparação dos dados	Como o próprio nome do arquivo já diz: ele já é um dataset já previamente processado o que nos trouxe uma categorização e lista de músicas já pré-organizada nos libertando do trabalho de fazer uma limpeza de dados antes de começarmos essa pesquisa exploratória. Mas vale dizer que a distribuição do stream count era assimétrica para apenas o lado da esquerda sendo muito acima da mediana e não sendo recomendado para uso em modelos de escala, mas utilizando logaritmo na distribuição em stream_count esse problema se resolvia. Também foi observado que a correlação era praticamente nula entre gênero musical e atributos de áudio como exemplificado acima
Estratégia experimental	A escolha do número de clusters foi feita pelo método do cotovelo (elbow method): calculamos o WCSS (Within Cluster Sum of Squares) do K-Means para k variando de 1 a 10, sobre as features de áudio padronizadas (StandardScale), e identificamos visualmente o ponto de inflexão da curva em k=4. A partir de k=4, o ganho de compactação (redução do WCSS) por cluster adicional passa a ser pequeno, o que justifica essa escolha. Depois de determinar esses clusters fizemos dois treinos de modelos e fizemos a comparação com e sem gênero: em vez de treinar um único modelo, o experimento foi desenhado como uma comparação controlada entre duas configurações de entrada para o mesmo K-Means.

	A configuração 1 usa somente as 9 features de áudio padronizadas; A configuração 2 usa essas mesmas 9 features combinadas com o one-hot encoding do gênero, padronizadas novamente em conjunto. Essa comparação foi o próprio desenho experimental do projeto: a Configuração 1 funcionou como linha de base, cujo resultado (clusters heterogêneos em gênero) motivou a mudança testada na Configuração 2. Reportar as duas configurações lado a lado, e não apenas a versão final, é o que evidencia o efeito real de incluir o gênero como feature. O ajuste do K-Means nas duas configurações foi feito sobre o dataset completo (85.000 faixas), sem divisão treino/teste, já que o objetivo aqui é comparar o efeito das features na formação dos clusters, não estimar erro de generalização. Como próximo passo, propomos validar a estabilidade dos clusters com uma divisão 80/20 estratificada por gênero: ajustar o K-Means só no treino e verificar se o teste, ao ser atribuído aos centróides já existentes, mantém Silhouette Score e composição de gênero parecidos aos do treino.
Modelagem	Algoritmo: K-Means, com k=4 (definido pelo método do cotovelo), random_state=42 e n_init=10, testado em duas configurações de features. Configuração 1 (somente áudio): as 9 features de áudio (duration_minutes, popularity, danceability, energy, loudness, instrumentalness, tempo, upbeat_score, log_stream_count) padronizadas com StandardScaler. Resultado: clusters com boa separação visual (ex. danceability vs. energy), mas heterogêneos em gênero, cada cluster misturava vários gêneros igualmente. Configuração 2 (áudio + gênero): as mesmas features de áudio combinadas com o one-hot encoding do gênero, padronizadas novamente em conjunto. Resultado: um cluster ficou 100% Metal, outro 100% Pop, e os outros dois concentraram os 10 gêneros restantes (inserir aqui a distribuição exata desses dois clusters).
Avaliação	Composição dos clusters (Configuração 1, somente áudio): os tamanhos dos 4 clusters, 19.466, 27.199, 26.628 e 11.707 faixas, não guardam relação com nenhum gênero específico. Isso se confirma na tabela de contingência gênero x cluster: cada um dos 12 gêneros aparece em proporção quase idêntica, entre 7,9% e 8,9%, dentro de todos os quatro clusters (o esperado por puro acaso seria $100\%/12 \approx 8,3\%$). Composição dos clusters finais (Configuração 2, áudio + gênero): os tamanhos dos 4 clusters, 7.200, 7.096, 35.038 e 35.666 faixas, coincidem exatamente com o total de Metal (7.200) e Pop (7.096) no dataset. Isso confirma que o Cluster 0 é 100% Metal e o Cluster 1 é 100% Pop, pureza perfeita nesses dois. Os outros 10 gêneros ficaram divididos entre os Clusters 2 e 3, que por isso têm pureza baixa (a calcular com a tabela completa de genre_new_cluster_percentage). Ou seja, os clusters são geometricamente coerentes (cada um com um perfil sonoro próprio), mas têm

	pureza de gênero praticamente nula, essencialmente equivalente a uma divisão aleatória em relação ao gênero. Qualidade da recomendação: no exemplo já rodado (música "Score", gênero Indie, Cluster 2 da Configuração 1), as 10 recomendações tiveram similaridade de cosseno entre 0,995 e 0,978, mas nenhuma delas era do gênero Indie (vieram R&B, Rock, EDM, Metal, Hip-Hop e Country). Ou seja, mesmo com scores de similaridade quase perfeitos, o recomendador baseado só em áudio não preserva o gênero da música de entrada. Essa é a métrica mais direta para reportar: taxa de correspondência de gênero nas recomendações. Sugerimos calcular essa taxa (% das N recomendadas que têm o mesmo gênero da música de entrada) usando o recomendador da Configuração 2 (com <code>kmeans_cluster_with_genre</code>), para pelo menos 3 exemplos: uma música de Metal, uma de Pop (esperado 100%, já que são clusters puros) e uma de outro gênero, caído em Cluster 2 ou 3 (esperado abaixo de 100%, por serem clusters mistos). Comparar essa taxa entre a Configuração 1 e a Configuração 2 é a evidência mais clara de que incluir o gênero melhorou a recomendação.
--	---